

SmolVLM2-256M LoRA 模型适配与长输出优化报告

芯溯猫猫队

2026 年 6 月

1 交付范围

本报告对应提交目录中的 LoRA 软件优化材料，范围限定为 SmolVLM2-256M 的 **LLM/text LoRA** 训练、合并、GGUF 导出、Q8 量化和验证证据。该部分不包含 ViT 训练、vision distillation、connector/mmproj 训练或图像预处理器训练。

LoRA 目标模块为：

```
q_proj, k_proj, v_proj, o_proj,  
gate_proj, up_proj, down_proj
```

交付包的主要文件包括：

- LoRA 交付包.zip: LoRA 文档、脚本、源码快照和证据文件压缩包；
- LoRA 交付包/README.md: 交付范围、结论和目录说明；
- LoRA 交付包/MANIFEST.md: 文件来源、校验和未复制大文件说明；
- LoRA 交付包/docs/: 问题分析、复现命令、指标和 caveat；
- LoRA 交付包/scripts/: 长回答生成、训练合并、评测和长度检查脚本；
- LoRA 交付包/src_snapshot/: LoRA-only 源码快照；
- LoRA 交付包/tests_snapshot/: 数据、评分、验证和 terminator loss 测试快照；
- LoRA 交付包/evidence/: multi-seed accuracy 和长度检查 JSON。

2 工程目标与约束

本方向的工程目标是在 256M 级视觉语言模型上，用 text LoRA 提升 OCR/VQA 类任务表现，同时保持可部署到 llama.cpp/GGUF 路径的模型形态。训练与部署约束如下：

- 推理模型规模保持在 SmolVLM2-256M 级别；
- 仅训练 text model 中的 LoRA 参数；
- 训练后可以 merge 到 Hugging Face checkpoint；
- merged text model 可以 export 为 text GGUF，配合 mmproj GGUF 使用；

- 不把视觉侧训练代码和模型权重混入本交付包。

该方向不是替代 KV260 板端运行时、bitstream 或 KV Cache 裁剪，而是作为软件优化材料中的模型适配路线：它解释了 256M 模型在 OCR/VQA 和长输出场景之间的权衡，并保留可复现的训练脚本与证据。

3 问题分析

3.1 短答案 accuracy 与长输出退化

早期 AICAS 标签 strong LoRA 在六个 quota seeds 上显著超过 500M reference:

模型/阶段	500M FP16	trained 256M	Delta	Pass
AICAS-label strong LoRA	3473/6000	4567/6000	+1094	true

但是同一模型在 `test2.jpg + LONG_PROMPT + max_tokens=4096` 的长输出场景下提前结束。这里的 `max_tokens=4096` 是输出上限，不是最小生成长度；模型自然输出 EOS 后会停止。HF 复现实测显示，256M base 本身可以生成较长输出，而旧 LoRA 只生成 16 tokens:

模型	prompt tokens	generated tokens	first EOS
500M base	1558	179	178
256M base	1558	276	275
旧 256M LoRA r64	1558	16	15

因此，问题主要来自微调数据分布和 loss 设计，而不是 256M 架构天然不能长输出。

3.2 根因

FullTest.json 的答案长度极短：median 约 6 字符/1 个词，约 41.5% 的答案不超过 5 个字符，约 76.2% 的答案不超过 10 个字符。数据主要服务 OCR 文本识别和短 VQA。

旧 answer-only loss 会将 prompt、user、image、template token mask 为 -100，只监督 assistant answer span。当训练集中绝大多数 answer 很短时，模型会被强化为：看到图像和短问题后，输出少量词，再迅速输出 `<end_of_utterance>`。

这解释了两个现象同时出现的原因：

- 短 OCR/VQA accuracy 提升明显；
- 长篇视觉分析 prompt 下出现过早 EOS。

4 优化路线

4.1 Public OCR/VQA LoRA

public-only 路线使用 TextVQA 与 OCR-VQA 数据，避免直接依赖 AICAS 标签。该路线用于验证数据转换、answer-only 训练、multi-seed validation、merge/export/quantize 等流程本身是可复现的。

转换后的 public 数据规模为 836,181 条，其中 TextVQA 34,602 条、OCR-VQA 801,579 条。短训练 subset 为 134,602 rows，包含全部 TextVQA 和 100,000 条 OCR-VQA。

4.2 Answer Span 与 Terminator Loss

源码快照中保留了 answer span 处理逻辑。对于 context-sensitive tokenization 情况，例如独立字符串 tokenization 与 chat span tokenization 不一致时，训练逻辑会 fallback 到基于 prompt length 的 assistant span。

--include-answer-terminator-loss 会额外监督 answer span 后紧邻的一个 terminator token。该设计避免在长序列中搜索远处 EOS，同时让模型学习 answer 边界。它不是强制模型长输出，而是让短答任务的结束行为更稳定。

4.3 Longform Recovery

longform 路线使用 500M teacher 为图像和 OCR/VQA 任务生成较长回答，再与短答案数据混合训练。代表性配置为：

- 生成 600 条通用 longform 样本；
- 每条样本目标长度约 450–650 tokens；
- short rows 约 57,817 条；
- longform rows repeat 10 后混入训练；
- 训练时启用 answer terminator loss。

该路线的作用是让模型区分短答 prompt 与长答 prompt：短答任务保持简洁，长篇分析任务保留继续生成能力。

4.4 Exact Throughput Continuation

exact throughput continuation 使用 throughput_eval.py 中相同的 LONG_PROMPT 生成 600 条 longform，再 repeat 30，用小学习率进行 1000-step continuation。该路线主要用于验证长输出长度能否进一步提升。

需要注意，continuation 的 Q8 长度有改善，但没有达到 500M Q8 baseline 的 80% parity；F16 长度更长，但存在重复和质量 caveat，不能替代 Q8 部署结论。

5 关键指标

5.1 Accuracy

阶段	Reference	Trained	Delta	Pass
AICAS-label strong answer-only	3473/6000	4567/6000	+1094	true
Public-only OCR/VQA	3473/6000	3749/6000	+276	true
longform600 repeat10 term	3473/6000	4297/6000	+824	true

Exact throughput continuation 6x100 smoke	341/600	415/600	+74	true
--	---------	---------	-----	------

其中 exact throughput continuation 是 6x100 smoke，不是完整 6x1000 gate。

5.2 长度与 EOS

模型	generated tokens	first EOS	tok/s
500M base	179	178	29.69
256M base	276	275	38.46
旧 256M LoRA r64	16	15	13.81

llama.cpp Q8 风格长度证据如下：

模型组合	eval runs	相对 500M Q8
500M Q8 baseline	457	100%
旧 short-EOS LoRA Q8	35	7.7%
longform600 repeat10 term Q8 text + base Q8 mmproj	160	35.0%
exact throughput continuation Q8 text	208	45.5%
exact throughput continuation F16 text	690	151.0%

上述数据说明：LoRA 长输出能力从旧 Q8 的 35 eval runs 提升到 continuation Q8 的 208 eval runs，但仍低于 500M Q8 baseline。F16 的 690 eval runs 只能作为长度探索证据，不能直接替代 Q8 部署路径。

6 复现入口

LoRA 交付包保留了训练、合并、导出和量化命令。典型流程如下：

```
smolvlm-kv260 train-lora \
  --train-json <train-json> \
  --image-root <image-root> \
  --output-dir <adapter-dir> \
  --lora-r 64 \
  --lora-alpha 128 \
  --include-answer-terminator-loss

smolvlm-kv260 merge-lora \
  --base-model <base-hf-model> \
  --adapter-dir <adapter-dir> \
  --output-dir <merged-hf-dir>
```

```
smolv1m-kv260 export-gguf \  
  --hf-model-dir <merged-hf-dir> \  
  --output-dir <handoff-dir> \  
  --name-prefix <name-prefix> \  
  --outtype f16  
  
smolv1m-kv260 quantize-q8 \  
  --input-gguf <handoff-dir>/<name-prefix>-f16.gguf \  
  --output-gguf <handoff-dir>/<name-prefix>-Q8_0.gguf
```

multi-seed accuracy 使用 6 个固定 seeds:

```
123 20260517 20260518 20260519 20260520 20260521
```

每个 seed 为 1000 quota rows; public-only 与 longform 路线使用 within-2pp gate, strong LoRA 路线使用更严格的 trained $\geq$ reference 规则。

7 已知限制

- 交付包不包含模型权重、adapter safetensors、GGUF、训练数据集、prediction dumps 或图片;
- AICAS-label strong LoRA 使用 FullTest.json, 适合说明 competition/in-pool 表现, 不代表无偏泛化;
- public OCR-VQA 使用 public non-gated HF mirror, 外部发布前仍需确认 license/provenance;
- max_tokens=4096 是上限, 不能用 --ignore-eos 结果证明自然长输出能力;
- Q8 mmproj 可能是 mixed tensor type, patch、position、bias、norm 等 tensor 可能保持 F32;
- llama.cpp Q8 与 KV260 FPGA runtime 的在线量化、重定标和 host-PL 协同路径不完全等价;
- exact throughput continuation 的 Q8 长度为 45.5% baseline, 仍需要后续质量检查和更完整的 6x1000 gate。

8 结论

LoRA 软件优化路线证明了 256M text model 在 OCR/VQA 短答案任务上可以通过轻量参数适配显著提升表现; 同时也说明, 短答案数据与 answer-only loss 会带来过早 EOS 风险。通过 public-only 数据验证、answer span 处理、terminator loss、longform mixed training 和 exact prompt continuation, 可以在保持短答 accuracy 的同时改善长输出长度。

本交付包保留的是可审查的脚本、源码快照、测试快照和证据 JSON; 大模型权重、训练数据和 GGUF 产物不直接放入提交目录, 只在 manifest 中记录来源路径和校验信息。

参考文献

1. Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. LoRA: Low-Rank Adaptation of Large Language Models. ICLR, 2022.
2. Amanpreet Singh, Vivek Natarajan, Meet Shah, Yu Jiang, Xinlei Chen, Dhruv Batra, Devi Parikh, and Marcus Rohrbach. Towards VQA Models That Can Read. CVPR, 2019.
3. Anand Mishra, Shashank Shekhar, Ajeet Kumar Singh, and Anirban Chakraborty. OCR-VQA: Visual Question Answering by Reading Text in Images. ICDAR, 2019.