

KV260 复赛测试说明

芯溯猫猫队

镜像启动、bitstream 加载、server 运行与官方测评流程

板卡	Xilinx KV260
交付包目录	/home/xilinx/kv260_llama_server_minimal
登录用户	xilinx
登录密码	xilinx
文档日期	2026-06-13

目录

1	测试目标	2
2	硬件与前置条件	2
3	SD 卡镜像写入	2
4	登录 KV260 并检查交付包	3
5	挂载数据集	3
6	检查系统并启动 llama-server	3
7	准备官方测评目录	4
8	运行官方测评	4
8.1	精度测试	4
8.2	吞吐量测试	5
8.3	能耗测试	5
8.4	TTFT 测试	5
9	合并结果	5
10	演示实测结果示例	6
11	验收检查点	6

1 测试目标

本文说明 KV260 复赛交付包的复现测试流程，用于验证以下内容：

- 完整 Linux 镜像可写入 SD 卡并启动 KV260。
- 使用 `xilinx / xilinx` 可登录正常系统。
- 交付包目录存在，脚本可完成 bitstream 加载与运行环境检查。
- `llama-server` 可在本地端口启动并保持运行。
- 官方测评脚本可输出精度、吞吐量、能耗、TTFT 结果，并合并为提交 JSON。

2 硬件与前置条件

项目	要求
板卡	Xilinx KV260，电源和网线连接正常。
存储卡	32 GB 以上 SD 或 microSD 存储卡，建议使用 64 GB 及以上容量，避免镜像写入空间不足。
镜像文件	<code>kv260_mmcblk1_resized32g_initramfs_20260612_1008.img</code> 或最终提交包中的同版本镜像。
主机工具	Linux/WSL 主机或其他可执行 <code>dd</code> 写盘工具的环境。
网络	KV260 与数据集 NFS 服务器在同一可达网络内。
登录账号	用户名： <code>xilinx</code> ；密码： <code>xilinx</code> 。
交付包路径	<code>/home/xilinx/kv260_llama_server_minimal</code> 。
数据集挂载点	示例挂载点为 <code>/mnt/share</code> ，实际测试以现场数据集目录为准。

3 SD 卡镜像写入

在主机上插入 32 GB 以上存储卡，确认实际设备名后写入镜像。以下命令中的 `/dev/sdX` 必须替换为真实 SD 卡设备，不能写成系统盘。

```
sudo dd if=kv260_mmcblk1_resized32g_initramfs_20260612_1008.img \  
  of=/dev/sdX \  
  bs=4M \  
  status=progress \  
  conv=fsync \  
sync
```

写入完成后，将 SD 卡插入 KV260 并上电启动。若演示视频需要展示完整链路，可保留 `dd` 命令开始、进度和完成输出。

4 登录 KV260 并检查交付包

KV260 正常启动后，通过 SSH 登录：

```
ssh xilinx@<KV260_IP>
```

登录信息：

```
username: xilinx
password: xilinx
```

进入交付包目录并检查文件：

```
cd /home/xilinx/kv260_llama_server_minimal
ls
```

目录中应包含：

```
README.md  SHA256SUMS  bitstream  harness  loader  models  python_env  runtime
scripts
```

5 挂载数据集

以下 NFS 命令仅作为挂载方式参考。实际测试时，请将服务器地址、导出路径和本地挂载点替换为现场可访问的真实数据集目录，并确认该目录内包含组委会要求的图片数据集和官方 JSON 文件。

```
DATA_MNT=/mnt/share
sudo mkdir -p "$DATA_MNT"
sudo mount -t nfs4 -o vers=4.0 <NFS_SERVER>:<DATASET_EXPORT> "$DATA_MNT"
findmnt "$DATA_MNT"
ls "$DATA_MNT"
```

后续精度测试命令中的 `-i` 参数应填写真实图片目录，`-d` 参数应填写组委会提供的官方 JSON 文件路径。若数据集已经通过其他方式放在本地，也可以不使用 NFS，直接填写实际本地目录。

6 检查系统并启动 llama-server

打开终端 1，先执行系统检查脚本：

```
cd /home/xilinx/kv260_llama_server_minimal
./scripts/check_system.sh
```

该脚本会依次完成：

- 加载 bitstream。

- 配置 XRT、DDR、PL 时钟。
- 检查 XDMA、内存窗口和 FCLK 状态。

检查通过时应看到：

```
PREPARE_OK
```

确认 PREPARE_OK 后，再启动 server：

```
cd /home/xilinx/kv260_llama_server_minimal
./scripts/start_server.sh
```

启动通过时应看到：

```
SERVER_OK
url=http://127.0.0.1:8080
```

服务地址：

```
http://127.0.0.1:8080/v1
```

终端 1 保持打开，server 前台运行。停止服务时执行：

```
cd /home/xilinx/kv260_llama_server_minimal
./scripts/stop_server.sh
```

7 准备官方测评目录

打开终端 2，执行：

```
cd /home/xilinx/kv260_llama_server_minimal
source python_env/.venv/bin/activate
RUN_DIR=~ /kv260_eval_runs/run_$(date +%Y%m%d_%H%M%S)
mkdir -p "$RUN_DIR"
cd "$RUN_DIR"
```

后续测评输出文件均保存在该运行目录中。

8 运行官方测评

8.1 精度测试

```
DATA_DIR=/path/to/actual/image_dataset
OFFICIAL_JSON=/path/to/official_ocrbench.json
python /home/xilinx/kv260_llama_server_minimal/harness/acc_eval.py \
-i "$DATA_DIR" \
-d "$OFFICIAL_JSON" \
```

```
-o acc_eval_results.json
```

输出文件: acc_eval_results.json。

8.2 吞吐量测试

```
python /home/xilinx/kv260_llama_server_minimal/harness/throughput_eval.py \  
-i /home/xilinx/kv260_llama_server_minimal/harness/test2.jpg \  
-o throughput_metrics.json
```

输出文件: throughput_metrics.json。

8.3 能耗测试

```
python /home/xilinx/kv260_llama_server_minimal/harness/energy_eval.py \  
-i /home/xilinx/kv260_llama_server_minimal/harness/test2.jpg \  
-o energy_metrics.json \  
--sample_hz 100 \  
--power_path /sys/class/hwmon/hwmon2/power1_input \  
--power_unit uW
```

输出文件: energy_metrics.json。如果板卡上的 hwmon 编号不同, 应以实际 power1_input 路径为准。

8.4 TTFT 测试

```
python /home/xilinx/kv260_llama_server_minimal/harness/ttft_eval_multiprompt.py \  
-c /home/xilinx/kv260_llama_server_minimal/harness/ttft_config.json \  
-o ttft_eval_results.json
```

输出文件: ttft_eval_results.json。

9 合并结果

四项测试完成后, 在同一运行目录执行:

```
python /home/xilinx/kv260_llama_server_minimal/harness/merge_results.py \  
--acc acc_eval_results.json \  
--throughput throughput_metrics.json \  
--energy energy_metrics.json \  
--ttft ttft_eval_results.json \  
-o aicas_submission.json
```

最终输出文件:

```
aicas_submission.json
```

建议记录各 JSON 文件的 SHA256，便于提交前复核：

```
sha256sum acc_eval_results.json throughput_metrics.json energy_metrics.json
ttft_eval_results.json aicas_submission.json
```

10 演示实测结果示例

以下为一次复现演示中的结果摘要，正式提交以实际运行官方脚本生成的 JSON 为准。

项目	示例结果
Accuracy	0.8000, 24 / 30
Throughput	Prefill 53.55 tokens/s, Decode 39.25 tokens/s
Energy	5.5912 tokens/J, 平均功耗 6.45 W
TTFT	slope 1.4685 ms/char, intercept 2600.84 ms
综合得分	87.72

11 验收检查点

测试完成后，应逐项确认：

- 使用 32 GB 以上存储卡写入镜像后，KV260 可正常启动。
- 可通过用户名 xilinx、密码 xilinx 登录系统。
- /home/xilinx/kv260_llama_server_minimal 目录存在且内容完整。
- 实际数据集目录可访问，精度测试命令中的 -i 和 -d 已指向真实路径。
- ./scripts/check_system.sh 输出 PREPARE_OK。
- ./scripts/start_server.sh 输出 SERVER_OK。
- llama-server 在 http://127.0.0.1:8080/v1 可用。
- 官方测评脚本生成精度、吞吐量、能耗和 TTFT 结果文件。
- merge_results.py 生成 aicas_submission.json。
- 结果 JSON 与提交文件已记录 SHA256 校验值。